

Soilframe-Voronoi: AutoML contínuo para déficit hídrico do solo

38 modelos treinados em 116 horas sobre 202.686 observações diárias

Instituto SENAI de Inovação em Química Verde

Firjan SENAI

Outubro de 2026

Prever o déficit hídrico de amanhã para decidir a irrigação

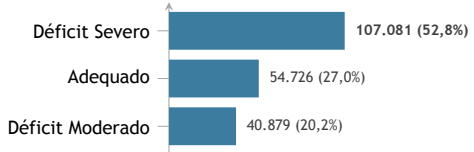
Visão executiva: problema de negócio e base de dados

Problema de negócio

Classificar a condição hídrica do solo de cada célula de Voronoi no **dia seguinte** (D+1) para apoiar a decisão de irrigar.

- Alvo do **AquaCrop** (FAO) com clima **ERA5-Land** do Lakehouse (2020–2024)
- **202.686** observações: 162.148 de treino (80%) e 40.538 de teste *holdout* (20%)
- **18 variáveis**: temperatura, chuva, ET_0, radiação, vento, balanço hídrico, chuva de 3 e 7 dias, calendário e coordenadas

Classes do alvo (desbalanceadas)



Total: 202.686 observações diárias.

Mais da metade dos dias é de seca severa. O Déficit Moderado é a menor classe e fica na fronteira entre as outras duas.

Firjan SENAI

Um AutoML que roda por dias e retoma de onde parou

Engenharia da busca contínua

Ciclo de cada iteração

1. Sorteia uma família e seus hiperparâmetros
2. Validação cruzada estratificada (5 partições)
3. Avalia no teste *holdout* e grava o *checkpoint*
4. A cada 12 iterações, monta um *ensemble* dos 3 melhores

Famílias exploradas

- Baselines: `DummyClassifier` (3 estratégias)
- Linear: LogisticRegression
- Árvores: RandomForest, ExtraTrees, AdaBoost, GradientBoosting, HistGradientBoosting, LightGBM
- Rede neural: MLPClassifier
- Meta-*ensemble*: StackingClassifier

Execução

18/10 19h04 → 23/10 15h45: ≈**116 h**
38 modelos: 3 baselines + 35 iterações

Resiliência

Checkpoint atômico a cada iteração: uma queda de energia não perde estado. Treino 100% *offline* sobre o Lakehouse; um *worker* baixa as UFs pendentes quando a cota da API reabre.

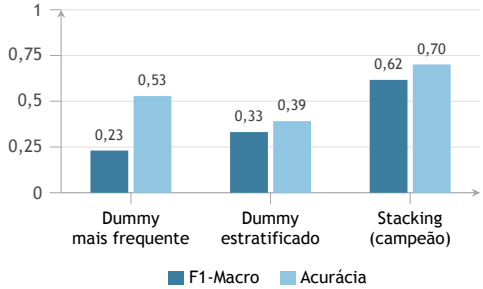
Quatro iterações (GradientBoosting #4, AdaBoost #5 e #10, HistGB #6) consumiram ≈109 das 116 horas.

Firjan SENAI

Acertar 52,8% sem aprender nada: a armadilha da acurácia

Linhas de base e escolha da métrica

Linhas de base (`DummyClassifier`, teste *holdout*)



Responder sempre “Déficit Severo” já dá 52,8% de acurácia, mas o modelo nunca reconhece uma lavoura saudável nem o estresse inicial.

Por que F1-Macro

É a média simples do F1 de cada classe. Um modelo que ignora uma classe é punido, mesmo que ela seja pequena.

Ganho do campeão sobre a baseline

F1-Macro: 0,2305 → **0,6167**
+38,6 p.p. (+167% relativo)

Firjan SENAI

Os cinco melhores modelos ficam a 1,1 p.p. de distância

Leaderboard geral (teste *holdout* de 40.538 amostras)

Modelo	Iter.	F1-Macro (CV)	F1-Macro	Acurácia	Treino
Stacking (LogReg)	12	0,6151 ± 0,0020	**0,6167**	70,10%	739 s
LightGBM	7	0,6123 ± 0,0017	0,6156	**70,14%**	**54 s**
HistGradientBoosting	31	0,6124 ± 0,0019	0,6134	70,00%	1.976 s
MLP (128, 64)	15	0,6019 ± 0,0027	0,6086	69,35%	675 s
RandomForest	1	0,6024 ± 0,0012	0,6056	69,49%	58 s
LogisticRegression	2	0,5738 ± 0,0017	0,5739	67,00%	11 s
Dummy estratificado	0	0,3337 ± 0,0016	0,3315	39,13%	2 s
Dummy mais frequente	0	0,2305 ± 0,0000	0,2305	52,83%	1 s

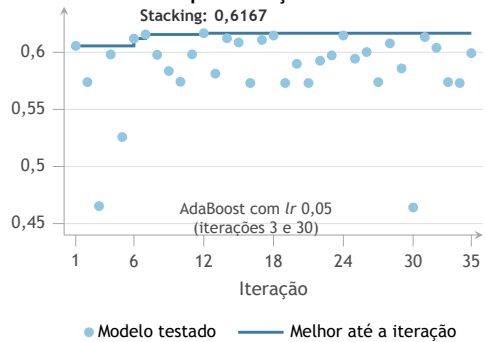
Árvores com *boosting* dominam o topo. A diferença entre o 1º e o 5º colocado (1,1 p.p.) é de cerca de cinco desvios-padrão da validação cruzada.

Fonte: `outputs/models/automl_checkpoint/leaderboard_historico.csv`.

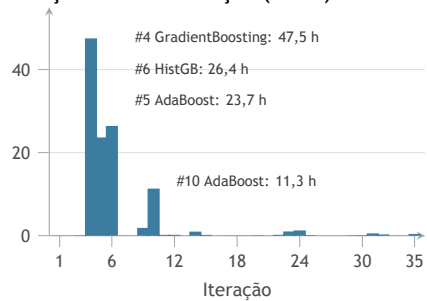
O recorde saiu na iteração 12 e não foi superado

Evolução do AutoML ao longo das 35 iterações

F1-Macro no teste por iteração



Duração de cada iteração (horas)



O campeão combina os três melhores modelos anteriores

StackingClassifier com regressão logística como meta-estimador (iteração 12)

Métricas globais (teste *holdout*)

Métrica	Valor
F1-Macro	**0,6167**
F1-Macro (CV)	0,6151 $\pm$ 0,0020
Acurácia	**70,10%**
Acurácia balanceada	61,55%
F1 ponderado	68,31%

28.418 acertos em 40.538 amostras. Desvio de 0,002 entre as partições: o resultado não depende de uma divisão favorável.

Arquitetura

Estimadores de base (top 3 até a iteração 11):

- LightGBM: profundidade 7, *lr* 0,15, 63 folhas
- HistGB: 200 iterações, *lr* 0,14, 127 folhas
- RandomForest: 100 árvores, profundidade 20, entropia

Meta-estimador: LogisticRegression (`max_iter=500`), treinado com previsões *out-of-fold* (`cv=3`)

Firjan SENAI

O modelo acerta os extremos e confunde a classe do meio

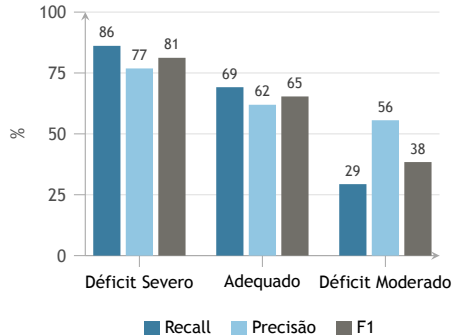
Matriz de confusão e métricas por classe (Stacking, teste *holdout*)

	Predito			
Real	**Adeq.**	**Moder.**	**Severo**	**Total**
Adequado	**7.570**	954	2.421	10.945
D. Moderado	2.643	**2.400**	3.133	8.176
D. Severo	2.006	963	**18.448**	21.417

Diagnóstico

Dos 5.776 dias de Déficit Moderado classificados errado, **3.133 (54%) viram Severo** e **2.643 (46%) viram Adequado**. O primeiro erro é conservador; o segundo pode atrasar uma irrigação.

Métricas por classe



9 em cada 10 dias de seca severa são previstos na véspera

Interpretação de negócio e impacto agrícola



- **Risco crítico coberto**: o alvo é o dia seguinte, então o alerta chega a tempo da irrigação de socorro
- **Alarme confiável**: 77% dos alertas de Severo se confirmam; os demais custam água, não safra
- **Lavoura saudável reconhecida**: 69% dos dias Adequados são identificados, evitando irrigar sem necessidade
- **Ponto fraco**: o estresse inicial (Moderado) só é reconhecido em 29% dos casos

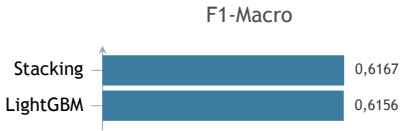
Mensagem para o produtor

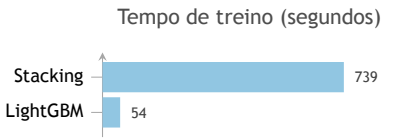
Confiável para “vai faltar água amanhã”; ainda não para “a falta de água está começando”.

Firjan SENAI

LightGBM: 99,8% do F1 com treino 14 vezes mais rápido

Trade-off técnico para produção em escala





Acurácia: 70,10% (Stacking) e 70,14% (LightGBM).

O tempo de treino inclui a validação cruzada e o ajuste final. O tempo de inferência não foi medido nesta execução.

Stacking: referência técnica

Maior F1-Macro (+0,1 p.p.), mas exige treinar e versionar três modelos e o meta-estimador.

LightGBM: candidato a produção

Um único modelo, treino 13,8× mais rápido e acurácia igual. Indicado para reprocessar todas as células todo dia.

Conclusões e próximos passos

Conclusões

- F1-Macro de **0,617**: 2,7× a baseline
- **86%** de recall na seca severa, um dia antes
- *Boosting* lidera; o Stacking vence por margem mínima
- 116 h de AutoML sem perda de estado

Técnicos

1. Validar com divisão **temporal** (treino 2020–2023, teste 2024) e espacial: a divisão aleatória pode superestimar o resultado
2. Escolher o campeão em validação própria, deixando o *holdout* só para o número final
3. Melhorar o Déficit Moderado: pesos de classe, limiares e abordagem ordinal
4. Incluir as UFs pendentes (MT, SE, SP, TO)

Operacionais

5. Piloto com LightGBM, medindo a latência de inferência
6. Validar os alertas com produtores parceiros em campo

Firjan SENAI

Obrigado(a) pela atenção!

Firjan SENAI